

PINN-PINO TwinMoE: 面向多时间尺度电池数字孪生的物理约束专家协同

张文鹏 (Wenpeng Zhang)

独立研究者

15184552744@163.com

技术报告中文阅读版 • 2026 年 10 月 9 日

代码与训练入口:

<https://github.com/fatasia/DeepMonkey-Studio/tree/main/research/battery-twin>

摘要

电池数字孪生同时面对跨循环退化和运行窗口内的电热变化,二者需要不同的物理约束与计算预算。本文介绍 PINN-PINO TwinMoE 的组件架构:以单颗粒物理头扩展退化模型,以轻量专家和谱算子专家估计瞬态状态,并在服务层区分执行的专家与最终采用的结果。方法展开物理损失归一化、数据与物理梯度冲突衰减,以及物理风险参与的条件执行。已有 HUST 77 电芯分析中,平均归一化 RMSE 从 0.166026 降至 0.162743,三项轨迹形状指标改善,平均 MAPE 则从 14.165708% 上升至 14.753008%。另一组 63 个合成场景记录了 0.018221 V 的电压 MAE。这些组件级结果表明,物理约束的收益需同时从误差、轨迹形状和运行成本判断。公开源码提供物理头和算子训练入口;健康上下文接口连接两类时间尺度,联合耦合收益尚未通过实验验证。

1 引言

一个始终调用最复杂模型的电池孪生可能付出不必要的计算成本;始终使用最快模型又可能忽视工况变化或物理失配。长期退化和瞬态状态也不能直接共用同一预测目标。本文研究的问题是:怎样让不同专家各司其职,并明确区分模型计算、物理约束和结果采用。

架构包含三个层次。退化模型以历史循环和电芯条件为输入,物理头为预测加入浓度场及有效参数约束;瞬态模型结合时间表示、径向谱算子与轻量专家;服务策略检查领域有效性和分歧,再决定采用哪个结果。健康上下文是时间尺度之间的显式接口,当前结果分别评价两类任务。

本文贡献是这套组件架构、可查阅的物理训练与条件执行机制,以及对已有实验取舍的分析。具体设计包括归一化物理损失、共享参数上的梯度冲突衰减、轻量/算子专家混合及物理风险参与的执行条件。我们报告这些机制的实现,区分已测得的组件结果和仍需验证的联合收益。

2 相关工作与设计定位

BatteryMFormer 提供退化轨迹预测骨干 [3]。PINO 已研究数据与微分方程约束的结合 [1], PIMO 已研究电池退化中的物理混合专家 [2]。本文的设计重点是物理扩展、瞬态专家的计算分工和部署时的结果采用。DeepSeekMoE 将专家专门化落实为可比较的架构选择 [4];本文的轻量/谱算子专家具有不同计算结构,与语言模型中的专家划分不同。梯度干扰已有通用研究,例如 PCGrad 的梯度投影 [5];本文实现的是物理损失权重衰减。

3 已实现的方法

3.1 任务接口与专家分工

设历史循环观测为 H ，运行窗口输入为 X ，可在窗口开始前获得的健康条件为 h 。长期专家输出退化量及有效物理参数；短期专家估计窗口内浓度、电压和温度。两个模型的目标和训练数据不同。图 1 中的虚线表示健康条件接口，不能据此推断已经完成联合端到端训练。




图 1: 模型计算与结果采用分层。虚线为已提供的健康上下文接口，其跨任务收益尚未评价。

3.2 长期物理信息专家

实现为 BatteryMFormer 主干增加了 BatterySPMPINNHead。电芯信息和实测曲线上下文用于估计浓度与有效物理参数。单颗粒约束覆盖径向扩散、表面通量、守恒、初始条件和电压一致性。径向扩散残差可示意为

$$\mathcal{R}_c = \partial_t c - \frac{D_{\text{eff}}}{r^2} \partial_r (r^2 \partial_r c),$$

其中，坐标缩放和有效参数由实现定义。中心及表面边界条件、积分约束与内部配点相互补充。其他损失项包括锂库存、按静置状态加权的开路电压锚定、化学体系先验、老化动力学及观测物理量。

训练目标结合预测项与物理项。每个物理损失按其当前绝对值缩放，该缩放值停止梯度传播并设置下限。诊断过程测量共享参数上数据梯度与物理梯度的余弦值；发生冲突时，将物理项的影响衰减至可配置的最小值。该机制是损失权重衰减，并非梯度投影。归一化的有效扩散参数需要结合独立几何和电化学信息，才能解释为材料本征扩散系数。

物理损失与梯度作用。 将各物理项记为 ℓ_k ，实现中的归一化为

$$L_P = \sum_k a_k \frac{\ell_k}{\text{stopgrad}(\text{clip}(|\ell_k|, 10^{-6}, 10^6))}. \quad (1)$$

其中 a_k 为配置权重。分母停止梯度，因此该形式调节不同物理项的梯度尺度。对同时受数据损失与物理损失影响的参数，记两梯度为 g_D, g_P ，诊断函数计算

$$\rho = \frac{\langle g_D, g_P \rangle}{\|g_D\| \|g_P\|}, \quad \alpha = 1 - (1 - \alpha_{\min}) \max(0, -\rho). \quad (2)$$

当梯度缺失或范数过小时使用 $\alpha = 1$ 。诊断的配置默认下界为 0.15；启用该控制的训练器还可配置更新间隔与平滑。上述公式说明已实现的机制，不表示归档的所有检查点均启用了同一配置。它保留相容梯度的物理权重，并减弱相反方向的作用；物理损失的下降和有效参数可识别性仍需分别评价。

3.3 短期物理信息算子

SPMPINOTransformer 将时序表示、径向谱模块与电热输出结合。令 $f_L(x)$ 和 $f_O(x)$ 分别表示轻量专家与算子专家的浓度预测， $w(x) \in [0, 1]$ 表示学习得到的算子权重，则软混合为

$$\hat{c}(x) = (1 - w(x))f_L(x) + w(x)f_O(x).$$

在 **dynamic** 模式下，两个专家都执行。在 **dynamic_sparse** 模式下，先执行轻量专家，当物理风险或学习得到的概率超过配置阈值时，才运行算子。当前原生 ONNX 导出使用 **dynamic** 模式。

模型接受可选的健康与退化上下文。已检查的训练路径由容量比、电流及电压统计量构造这些上下文。因此，架构提供了跨时间尺度的条件输入接口；将长期 PINN 的输出直接交给短期 PINO 并测量其效果，仍是待完成的实验。该框架并不假定所有专家都经过端到端联合训练。

3.4 三个层级的专家协同

层级	决策与保留的信息
模型内部	学习轻量专家与算子专家的权重；稀疏模式还使用物理风险阈值。
寿命预测	规则检查外推、置信度、适用域告警及标准专家与 PINN 的分歧，随后选择采用的寿命结果。
孪生运行时	规则在符合条件的 PINO、电热基线和物理 SPM 回退之间选择，保留备选预测及模型身份。

寿命策略标记高外推、拟合较弱或置信度不足的情况。较大专家分歧需要同时达到绝对阈值和相对阈值。孪生运行时提取有界的终态 SOC 与温度作为提交状态。日志区分实际执行的专家和最终采用的专家，以便分析被拒绝的预测与回退成本。

执行与采用的区别。 令 $r(X)$ 为归一化物理风险， $p_O(X)$ 为学习得到的算子执行概率。稀疏路径的调用条件可写为

$$z(X) = \mathbf{1}\{r(X) > \tau_r \vee p_O(X) > \tau_p\}.$$

阈值与具体特征由模型配置决定。 $z = 0$ 时跳过算子计算； $z = 1$ 表示执行算子，不等同于服务最终采用其结果。服务策略继续检查模型版本、领域范围、置信度和专家分歧，并保留备选结果。这样的分层把计算预算与运行时结果选择分开；应分别测量调用比例、实际延迟、误差与拒绝率。

3.5 部署

平台为寿命推理与瞬态推理提供独立的原生 ONNX 模型包。部署路径由 Rust 宿主执行，不依赖 Python/PyTorch 运行时。预测伴随模型来源和适用域检查。导出模型与研究模型的数值一致性、请求延迟和模型交接行为，需要与预测精度分别评价。

4 数据与评价方案

已检查的固定合成对照包含 LFP 电热数据集中的 1,255 个训练场景、127 个验证场景和 63 个测试场景。这些是仿真场景，并非 1,445 个独立实测电芯。正式发表前，需根据数据清单核实分组、生成参数、失败记录和源电芯标识。

推理任务也需要明确。对照脚本调用的评价函数，其模型包装器默认采用 `observer` 模式；独立的 `forecast` 模式将电压上下文限制在历史前缀中。因此，现有观测器路径结果不能单独证明因果意义上的未来预测。选定检查点是否实际使用了可用电压上下文，须由其配置确定。最终实验将分别评价观测器推理与基于历史前缀的预测，声明预测截止点及已知控制输入的假设。

4.1 路由评价口径

归档评估器使用当前执行模式返回的专家输出生成参考标签；稀疏模式下，未执行算子的输出被替换为轻量专家输出。因此不同策略面对的参考会改变，本文不以该路由准确率比较策略。有效对照应先离线运行固定的两位专家，为每个样本建立相同参考，再独立测量在线选择的误差和成本：

$$y^*(X) = \operatorname{argmin}_{e \in \{L, O\}} [\ell_e(X) + \lambda C_e].$$

该式给出评价规范，不是本报告已完成的新增实验。归档的电压、浓度、温度误差及请求时间在上下文保留其原测量范围。请求延迟和批量延迟分别报告，调用比例不直接换算成加速比。

5 已有实验记录

以下数值转录自己已有产物，本稿未重新训练模型。2026 年 7 月的固定对照使用检查点 `spm-pino-transformer-lfp-v10-6-speed-first`，应与后续带保护机制或迁移版本的检查点分别报告。

指标	Dynamic	Dynamic sparse
浓度 MAE（源记录归一化）	0.008161	0.008711
电压 MAE（V）	0.018221	0.018236
温度 MAE（°C）	0.159237	0.159237
平均请求延迟（ms）	5.955382	5.675562
请求 P95 延迟（ms）	8.588700	7.843700

由于历史参考标签随执行模式变化，表中不列路由准确率。请求计时包含 189 次重复调用，并非 189 个独立场景。记录中的批量 P95 延迟分别为 dynamic 的 7.007 ms 和 sparse 的 32.240 ms，说明请求级和批量测量不能支持全面加速的结论。计时环境与方案还需重新核验。

三个优化随机种子的汇总记录中，电压 MAE 均值为 0.017967 V，样本标准差为 0.001933 V；浓度 MAE 的变异系数为 17.82%。种子 2026 的检查点名为 `speed-first`，另外两个为 `full-seed` 变体。在将其解释为严格只改变随机种子的实验前，需要检查配置是否一致。这些记录也未建立基于统一参考的三种子稀疏路由准确率。

5.1 退化与物理一致性

已有 HUST 分析采用 77 个电芯标识、20,000 次 bootstrap 重采样，以及六项经 Holm 校正的配对检验。表 1 报告以电芯汇总、采用源记录归一化的结果。其整数据源留出设置仍需

指标	标准专家	PINN
RMSE（归一化）	0.166026	0.162743
MAPE（%）	14.165708	14.753008
单调性违反率	0.364614	0.337601
超额变化 RMS	0.006793	0.005608
平滑性 RMS	0.018637	0.015769

表 1: 已有 HUST 电芯级分析；这些指标均为越低越好。

对上游训练与校准成员进行最终核查。RMSE 均值差为 -0.003283 ，bootstrap 95% 区间为 $[-0.005754, -0.000627]$ ，Holm 校正后的配对检验 $p = 0.00644$ 。在三项已记录的形状指标上，77 个电芯均更有利于 PINN。但平均 MAPE 增加了 0.587300 个百分点，体现了逐点相对误差与轨迹形状之间的取舍。

三次内部 PINN 优化记录的 MAPE 分别为 1.350986%、1.3208274% 和 1.3223664%，均值为 1.3313933%；记录中的标准模型为 1.2129676%。移除化学体系条件后，三次配对运行的 MAPE 均变差，平均增加 0.0584 个百分点。参数冻结消融记录了较大的表面通量误差，说明评价物理参数辨识时，仅考察预测误差并不充分。




图 2: 由 HUST 77 电芯分析中记录的均值计算相对变化。柱条表示汇总均值的比值，并非逐电芯百分比变化的均值；图中不表示置信区间。

6 局限与后续实验

合成浓度标签不能验证实测电芯内部的浓度场。接近零的 SOC 误差可能来自基于守恒的共同构造，而非独立传感器验证。局部 Jacobian 扰动不能证明全局稳定性；两个大容量目标电芯不足以建立广泛跨域迁移；单个电池包上的图残差结果如果未优于简单基线，也不足以证明电池包泛化能力。

后续联合研究将在电芯隔离任务上比较始终使用标准专家、始终使用物理专家、纯规则、纯学习和组合策略。实验将固定反事实专家标签、声明预测截止点，并消融健康上下文。除配对误差与形状指标外，还将报告算子调用、拒绝率、状态连续性，以及同步测量的请求和批量延迟。最终评价前固定实测电压目标与数据源成员。

7 可复现性与披露

公开代码与训练入口位于 DeepMonkey-Studio 的 [research/battery-twin](#)。该目录提供 PINN 物理头、PINO 模型、训练脚本、生成样本、测试与逐文件来源哈希；README 给出独立安装和最小训练命令。平台专家采用逻辑位于 [batteryExpertRouting.ts](#)。完整 BatteryMFormer 微调仍需独立的上游适配、数据和权重；本次源码发布不等同于已归档实验检查点。

现有证据按源路径和 SHA-256 建立索引。已检查的七项实验清单与当前产物字节一致。源版本为 501e430095b5，完整哈希保存在证据索引中；由于存在本地修改，还需要逐文件哈希。公开发布需要确定代码与数据权限、固定依赖、记录检查点哈希、提供可执行评价命令并重新生成结果表。

生成式 AI 辅助了源码检查、内容组织和论文起草。

8 结论

PINN-PINO TwinMoE 将退化物理约束、瞬态轻重专家和服务结果采用组织为不同职责。公开实现使损失归一化、梯度冲突衰减和条件执行可以被逐项检查。已有数据说明：物理约束改善部分轨迹指标时，相对误差仍可能变差；减少专家调用也不能自动推导批量加速。本文因此将精度、物理形状、计算和结果采用分开描述，并将健康上下文的联合收益留给同一任务上的受控验证。

参考文献

- [1] Z. Li et al. Physics-Informed Neural Operator for Learning Partial Differential Equations. arXiv:2111.03794. <https://arxiv.org/abs/2111.03794>.
- [2] X. Huang et al. Physics-informed mixture of experts network for interpretable battery degradation trajectory computation amid second-life complexities. arXiv:2506.17755, 2025. <https://arxiv.org/abs/2506.17755>.
- [3] R. Tan et al. BatteryMFormer: Multi-level Learning for Battery Degradation Trajectory Forecasting. arXiv:2605.27044, 2026. <https://arxiv.org/abs/2605.27044>.
- [4] D. Dai et al. DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models. arXiv:2401.06066, 2024. <https://arxiv.org/abs/2401.06066>.
- [5] T. Yu et al. Gradient Surgery for Multi-Task Learning. NeurIPS, 2020. <https://arxiv.org/abs/2001.06782>.